

Uso de Técnicas de Aprendizado de Máquina para a Diferenciação de Lesões Isquêmicas e Desmielinizantes em Imagens de Ressonância Magnética

Luís Antônio Almeida Lima Vieira (221045) , Márcio Vinícius de Jesus Almeida (240781) ,
Nathan Shen Baldon (242448)

{1221045@dac.unicamp.br, m240781@dac.unicamp.br, n242448@dac.unicamp.br }

Departamento de Engenharia de Computação e Automação (DCA)
Faculdade de Engenharia Elétrica e de Computação (FEEC)
Universidade Estadual de Campinas (Unicamp)
Campinas, SP, Brasil

Resumo – Este artigo descreve o trabalho referente ao projeto final da disciplina de Aprendizagem de Máquina (IA048), ministrada pela Faculdade de Engenharia Elétrica e Computação da UNICAMP. O principal objetivo deste trabalho é apresentar e testar uma aplicação real de Aprendizagem de Máquina, ligada à classificação de lesões cerebrais, detectadas por imagens de ressonância magnética. A partir desta aplicação, é feita uma comparação de desempenho entre um classificador simples por Máquinas de Vetores Suporte (SVM), com pré processamentos e extração de atributos dos dados, e um classificador que aplica a ideia *Deep Learning*, através de uma rede neural complexa. Ambos os classificadores (com SVM e *DL*) tiveram ótimos resultados, apresentando acurácias maiores que 90%.

1. Introdução

O aprendizado de máquina, em especial na área de classificação, a cada dia se torna uma ferramenta poderosa em diversas áreas da sociedade. Um ramo promissor para uso desta ferramenta está na área da saúde, em especial no auxílio do diagnóstico por imagem, seja aumentando a precisão na detecção de tumores ou lesões, ou na diferenciação de doenças que possuam muitos padrões de similaridade. Para este último caso abordado, há uma grande dificuldade na diferenciação das características das imagens através da análise visual feita por um ser humano. Um exemplo de imagens médicas com grande similaridade são as imagens de lesões cerebrais capturadas por ressonância magnética (MRI) do cérebro. Diversas complicações na região do sistema nervoso central, como lesões decorrentes do lúpus, o acidente vascular cerebral (AVC) e a esclerose múltipla (EM), possuem além de sintomas iniciais semelhantes, lesões quase indiferenciáveis quando vistas em imagens de ressonância magnética (MRI) [6], onde os casos apenas podem ser diagnosticados a longo prazo com auxílio de profissionais, ou com auxílio de outras técnicas, como as imagens de difusão (DWI) ou a espectroscopia (MRS) [5].

Diante das barreiras apresentadas, se faz necessária a busca por uma ferramenta que possa ser eficiente na diferenciação das lesões, e também realizar tal tarefa utilizando dados estruturados da forma mais simples possível. Para a tarefa de reconhecimento de padrões, os classificadores baseados em aprendizagem de máquina possuem um grande potencial. Frente a isso, neste trabalho fo-

ram realizados testes com dois tipos diferentes de classificadores binários, para o aprendizado supervisionado de classificação de imagens de ressonância magnética entre imagens de lesões isquêmicas (proveniente de AVC) e de lesões desmielinizantes (provenientes de Esclerose Múltipla), avaliando o desempenho dos classificadores e a capacidade de replicação em dados distintos. Além dos testes de aplicação médica, este trabalho tem como finalidades utilizar técnicas de aprendizagem de máquina a partir de dados reais, que precisam de um tratamento diferente com relação à *datasets* públicos, como o *MNIST* [8]. Outra finalidade é comparar o desempenho de um classificador, que recebe como entrada uma extração de atributos dos dados, com um classificador baseado em *Deep Learning*, que recebe como entrada os dados brutos. Os classificadores testados foram *Support Vector Machine* (SVM) com a extração de atributos e uma Rede Neural Convolucional (CNN), baseada na *ResNet*.

2. Análise e Descrição do Dataset

Os dados utilizados são dados reais e não públicos, organizados em pastas que contém imagens de ressonância magnética (MRI), anonimizadas e simplificadas, de pacientes saudáveis, de pacientes com lesão cerebral "isquêmica" (AVC), e de pacientes com lesão cerebral "desmielinizante" (EM). Todas as imagens de lesão "isquêmica" e de lesão "desmielinizante", são acompanhadas por uma máscara, que delimita a região da lesão. Esta delimitação foi realizada por um profissional da saúde. As máscaras quando aplicadas às imagens isolam a região de interesse

da lesão.

Para o tratamento dos dados e para a classificação com SVM, foi explorada análise de imagens e extração de atributos de histograma. No entanto, como o foco do projeto é o treinamento dos classificadores e aprendizagem de máquina, o código e as escolhas feitas para estas etapas não foram elaborados por este grupo, sendo autorizadamente inspirados em outro projeto de outra disciplina cujo foco era o processamento das imagens.

Os nomes dos arquivos de imagens seguem o padrão XXX_FLAIR_Y, sendo XXX o número de identificação do paciente e Y o número da fatia do cérebro. Os arquivos de máscara possuem o mesmo nome do respectivo arquivo de imagem, seguido pela identificação _mask. As imagens estão separadas em uma pasta de AVC e outra pasta EM. Nessas pastas há também imagens normais.

Para a tarefa de classificação deste trabalho, é preciso montar, a partir do conjunto de dados completo, um *dataset*, com apenas as imagens de lesão, portanto, é preciso selecionar apenas as imagens que possuem máscara. Foi utilizada uma função, fornecida pelos proprietários do *dataset*, responsável por ler as imagens de lesões e as respectivas máscaras, salvando todos os arquivos de lesão e seus respectivos nomes em listas, escolhendo somente os dados úteis para esta classificação.

Foi verificado que algumas máscaras muito grandes estavam isolando regiões desnecessárias, considerando as posições das lesões. Foi feita uma análise da quantidade de *pixels* de valor 1 nos arquivos de máscara, e as poucas imagens com máscaras incorretas foram retiradas. As figuras 1 a 4 mostram máscaras corretas e incorretas de ambas as classes. Após essa correção, o *dataset* final ficou com 541 imagens e máscaras da classe AVC e 611 imagens e máscaras da classe EM, para o conjunto de treinamento. Este procedimento foi realizado para ambos os classificadores, para manter a padronização dos dados.




Figura 1. Imagem de AVC com a máscara correta.




Figura 2. Imagem de AVC com a máscara incorreta.




Figura 3. Imagem de EM com a máscara correta.




Figura 4. Imagem de EM com a máscara incorreta.

Vale ressaltar que no conjunto de treinamento do *dataset* final há imagens nos formatos (480,480), (448, 448) e (512,512), para a classe AVC e para a classe EM. As imagens do *dataset* possuem apenas um canal, são do tipo *uint8* e as máscaras são do tipo *int32*, com valores 0 ou 1.

Os dados de testes, estão presentes em uma outra pasta, e foram importados de forma semelhante. O conjunto de testes possui 225 imagens e máscaras de formatos (448,448) e (512,512), do mesmo tipo das imagens de treinamento. Os rótulos de teste, foram importados de um arquivo *.txt*. Esses rótulos estão em uma ordem diferente da ordem dos arquivos de teste, por isso, estes foram ordenados de acordo com o número das imagens de teste, para facilitar a comparação com os valores previstos.

3. Classificação com SVM

3.1. Preparação dos dados para o SVM

Para o uso do SVM para a classificação binária em questão, não é interessante aplicar os dados brutos na entrada do classificador. Assim, utilizou-se atributos de histograma, o que exigiu um pré-processamento das imagens, sendo essa uma grande diferença em relação a modelos de *Deep Learning*, os quais recebem dados brutos para classificação.

Para a diminuição dos atributos do SVM foram feitos alguns pré processamentos nos dados do *dataset*. Primeiramente foi feita uma normalização *MaxMin*, para deixar todos os *pixels* das imagens com valores entre 0 e 1. Após isso, foi isolada a região de interesse das imagens, através da aplicação das máscaras nas imagens. Com as regiões de interesse das imagens normalizadas, foi calculado o histograma, para todos os dados com 256 *bins* (um para cada *pixel* da imagem). O histograma representa a frequência com que cada intensidade de *pixels* ocorre em cada imagem, e os histograma para duas ima-

gens são mostrados na figura 5. A partir do histograma, é possível calcular atributos que representam os dados, e para obter esses atributos, foi utilizada a função *histstat* [1]. Esta função extrai, a partir do histograma, valores de média, variância, *skewness*, *kurtosis*, percentis (1, 10, 25, 50 (mediana), 75, 90, 99), entropia, moda e energia. Com isso, substituindo as imagens pelos seus respectivos atributos de histograma. A classe AVC foi atribuída com o rótulo 0 e a classe EM foi atribuída com o rótulo 1. O mesmo procedimento de extração de atributos foi aplicado para os dados de teste.




Figura 5. Histograma de uma imagem para a classe AVC e EM.

Com os dados de treinamento, contendo os atributos de histograma, em mãos, foi feita a separação em um conjunto de treinamento e um conjunto de validação, para o uso nas otimizações dos hiperparâmetros do SVM. Esta separação não pode ser aleatória, pois nos dados de treinamento há imagens distintas de um mesmo paciente, sendo necessário evitar a repetição excessiva de um paciente em um mesmo conjunto. Para isso, foram escolhidos 10 pacientes diferentes de cada rótulo para compor o conjunto de validação, de forma a diversificar os pacientes neste conjunto. Com isso, foi obtido um conjunto de treinamento com 926 imagens (434 da classe 0, e 492 da classe 1), e um conjunto de validação com 226 imagens (107 da classe 0 e 119 da classe 1). Os atributos de histograma foram chamados de x_{train_h} , x_{valid_h} , x_{test_h} , para os conjuntos de treinamento, validação e teste, respectivamente, e os rótulos foram chamados de y_{train_h} , y_{valid_h} , y_{test_h} .

3.2. Escolha do modelo

Após o processamento inicial e extração dos atributos de histograma, foi iniciado o processo de treinamento do classificador com SVM. Como entrada para o classificador, escolheu-se utilizar todos os atributos de histograma obtidos. Inicialmente, escolheu-se o LinearSVC [7], por ter processamento muito mais rápido, seguindo a metodologia de escolha proposta no livro-texto [3].

Com testes simples iniciais, obteve-se bons resultados e concluiu-se que os dados de entrada estavam sendo utilizados corretamente e que o processamento era de fato rápido, tal que várias combinações de hiperparâmetros poderiam ser testadas na validação cruzada.

3.3. Validação Cruzada

Inicialmente, avaliou-se o uso do GridSearchCV para validação cruzada, ideia esta descartada devido ao perigo do uso de imagens de um mesmo paciente em diferentes conjuntos (validação e treinamento). Assim, as possíveis combinações foram testadas com *'fors'* aninhados, de forma que os melhores hiperparâmetros foram escolhidos conforme a acurácia (calculada com a função *'sklearn.metrics.accuracy_score()'*). Não utilizou-se k-fold, tal que sempre testou-se os mesmos conjuntos de treinamento e validação separados anteriormente.

Os seguintes hiperparâmetros com os respectivos possíveis valores foram ajustados: **penalty**: norma utilizada para penalização, testou-se *l2* e *l1*; **loss**: função custo, testou-se *squared_hinge* e *hinge*; **dual**: seleciona forma de otimização. *False* é o recomendado quando $n_samples > n_features$, que é o caso deste projeto. No entanto, *dual=True* também foi testado por curiosidade; **tol**: tolerância para convergência, testou-se 10^{-1} , 10^{-2} , 10^{-3} , 10^{-4} , 10^{-5} , 10^{-6} ; **C**: estritamente positivo e inversamente proporcional a intensidade de regularização, testou-se 0.1, 1, 10, 50 e 100; **class_weight**: para balanceamento das classes, testou-se *None* ou *'balanced'*, apesar de não haver desbalanceamento grande entre as classes; **fit_intercept**: ajusta o local de intersecção da fronteira linear de decisão no espaço dos atributos. Testou-se *'True'* e *'False'*; **intercept_scaling**: testou-se 0.1, 1, 5, 25 e 100; **max_iter**: número máximo de iterações, para permitir que haja convergência no treinamento e também para evitar *overfitting*. Testou-se 10, 50, 100, 500, 1000, 5000 e 10000.

Testando-se todas as combinações, obteve-se o seguinte melhor arranjo de hiperparâmetros, com uma acurácia de 92,03% no conjunto de validação: **'penalty'**: *'l2'*, **'loss'**: *'squared_hinge'*, **'C'**: 1, **'dual'**: *True*, **'tol'**: 0.1, **'class_weight'**: *None*, **'fit_intercept'**: *True*, **'intercept_scaling'**: 5, **'max_iter'**: 50.

Note que testou-se quase todas as possibilidades de hiperparâmetros, uma vez que o processamento era rápido e permitia que certas combinações menos promissoras fossem testadas por curiosidade. À princípio, esperava-se que o melhor modelo tivesse os parâmetros *dual = False* (pois $n_samples > n_features$) e *loss=squared_hinge*, por ser a função custo compatível com *dual = False*. Além disso, acreditava-se o balanceamento entre as classes não

melhoraria o modelo. No entanto, obteve-se o contrário do esperado (exceto sobre o balanceamento de classes).

3.4. Aplicação do melhor classificador LinearSVC no conjunto de testes

Após a escolha dos melhores hiperparâmetros, fez-se o treinamento do melhor classificador LinearSVC (com conjunto de treinamento + validação) e a classificação das imagens do conjunto de teste. Obteve-se uma acurácia de 98,66% e ótimos resultados nas outras métricas também (Figura 6). Além disso, a matriz de confusão da classificação está apresentada na Figura 7. Note que há pouquíssimas classificações erradas, sendo que a diagonal principal da matriz apresenta quase todos as imagens do conjunto de teste.

acurácia teste: 0.9866666666666667				
	precision	recall	f1-score	support
0	1.00	0.96	0.98	79
1	0.98	1.00	0.99	146
accuracy			0.99	225
macro avg	0.99	0.98	0.99	225
weighted avg	0.99	0.99	0.99	225

Figura 6. Métricas obtidas na classificação do conjunto de teste com o melhor LinearSVC




Figura 7. Matriz de confusão da classificação do conjunto de teste com a melhor LinearSVC.

4. Classificação com CNN

4.1. Preparação dos Dados para a CNN

Diferentemente do SVM, as CNNs são amplamente empregadas na classificação através de padrões em imagens [2] e por isso, as imagens do *dataset* foram usadas por completo. Para uma comparação fiel dos modelos testados, a separação feita foi a mesma aplicada ao SVM, com a diferença que não há a aplicação das máscaras nem extração de atributos, já que a CNN já terá o papel de de-

tectar as regiões de interesse, e destacar partes das imagens relevantes. Portanto, foi utilizado o mesmo *dataset*, com um conjunto de treinamento com 926 imagens (434 da classe 0, e 492 da classe 1), um conjunto de validação com 226 imagens (107 da classe 0 e 119 da classe 1) e um conjunto de teste com 225 imagens. Os conjuntos das imagens brutas foram chamados de x_{train} , x_{valid} , x_{test} , para os conjuntos de treinamento, validação e teste, respectivamente, e os rótulos foram chamados de y_{train} , y_{valid} , y_{test} . Todas as imagens foram previamente normalizadas pelo *MaxMin*, de forma a manter as intensidades dos *pixels* entre 0 e 1.

Como para este tipo de modelo os dados devem possuir a mesma estrutura, todas as imagens com dimensões maiores que 448x448 *pixels* foram remodeladas para o tamanho citado. Verificando visualmente o redimensionamento, concluiu-se que não houve perda significativa de elementos estruturais importantes das lesões. A figura 8 traz um exemplo de uma imagem redimensionada.




Figura 8. Imagem de tamanho 512x512 redimensionada para uso na CNN.

4.2. Modelo e Treinamento

A estrutura de rede neural convolucional utilizada para a classificação foi a *ResNet* [4] de 34 camadas. Tal estrutura possui em boa parte de sua composição as chamadas unidades residuais, conhecidas pela sua eficiência na aceleração do processo de aprendizado por permitir a criação de atalhos para o fluxo de informação durante o treinamento [3]. Da estrutura original presente no livro-texto [3], foram realizadas algumas adaptações, como a recepção de imagens de dimensões (448,448) com apenas 1 canal (escala de cinza) na camada de entrada, bem como a diminuição do tamanho do *kernel* de 7x7 para 5x5. Além disso, a camada de saída foi também alterada para que se obtivesse um resultado binário de classificação, já que o *dataset* é composto apenas de duas classes.

No treinamento, todos os dados de treino passaram pelo modelo, com um *batch size* de 10 amostras a cada correção. Foram configurados um total de 30 épocas, suficiente para que haja a ação do *early stopping*, com

uma paciência de 3 épocas sem mudanças significativas no desempenho do modelo quando este é avaliado através dos dados de validação, este último procedimento é importante para evitar um *overfitting* durante o treinamento. A busca por hiperparâmetros não foi realizada, devido à complexidade do modelo e ao custo computacional. Os resultados da *ResNet*, para os dados de validação, foram testados com algumas poucas variações manuais de parâmetros de treinamento, para verificar se há a ocorrência de *overfitting*. Devido à estrutura da rede foram obtidos na maioria das vezes bons resultados. Para os dados de validação, foi obtida com o melhor classificador, uma acurácia de 0,92. Devido à complexidade da rede houve uma pequena variação nos valores de acurácia a cada treinamento, devido à aleatoriedade neste processo.

4.3. Aplicação da CNN no Conjunto de testes

Após o término do treinamento, os dados de teste foram aplicados para predição, de modo a avaliar como o melhor modelo se aplica à dados nunca antes vistos. Assim como no SVM, as previsões foram feitas na ordem das imagens na pasta de teste, e para a comparação com os rótulos corretos, os rótulos previstos foram ordenados pelo número das imagens, na mesma ordem realizada anteriormente. As métricas para o conjunto de teste estão na figura 8, e a matriz de confusão está na figura 9. A figura 10 mostra algumas previsões por arquivo, em conjunto com o rótulo original.

	precision	recall	f1-score	support
0	0.99	0.94	0.96	79
1	0.97	0.99	0.98	146
accuracy			0.97	225
macro avg	0.98	0.96	0.97	225
weighted avg	0.97	0.97	0.97	225

Figura 9. Métricas para o conjunto de teste, obtidas pela CNN.




Figura 10. Matriz de confusão para a CNN.

Assim como no caso do SVM, as previsões para os dados de teste foram melhores do que as previsões para os dados de validação. Uma possível explicação para isso tem a ver com as características dos dados no conjunto de teste, que possivelmente possuem características no geral mais próximas dos dados de treinamento. Apesar deste fato diferente, tanto os dados de validação, quanto os dados de teste foram classificados com uma alta taxa de acerto pelo classificador com a CNN. Os resultados do SVM e da CNN se aproximaram muito, o que demonstra que os dois modelos são capazes de classificar quase perfeitamente os dados de lesões cerebrais.

5. Conclusões

Neste trabalho foi possível verificar como lidar com dados reais, provenientes de arquivos de imagens, separados em pastas, tratando as imperfeições, para construir um *dataset*, com um formato correto para o uso de técnicas de Aprendizagem de Máquina. Além disso, foi possível ver como tratar de forma correta dados ligados à medicina, que representam uma aplicação promissora do Aprendizado de Máquina.

Com os dados obtidos, foi feita a comparação entre um classificador simples feito com SVM, e um classificador feito com uma rede neural amplamente utilizada, aplicando o conceito de *Deep Learning*. Após a comparação, conclui-se que ambos classificadores apresentaram bons resultados para os dados de teste e validação. O svm tem processamento mais leve e rápido que CNN, mas seu bom desempenho depende de um bom pré-processamento. A grande vantagem do uso do SVM, é o uso de pré-processamentos já consagrados na área de saúde, que utilizam diversos conhecimentos humanos, facilitando a classificação por Aprendizagem de Máquina. A grande vantagem do uso da CNN, é a facilidade de uso, por não ter a necessidade de desenvolver um pré processamento, já que a própria rede já delimita as regiões importantes para a classificação correta, porém este procedimento é muito custoso, e está sujeito à resultados ruins do ponto de vista da área da saúde.

Referências

- [1] Mariana P. Bento. libtexture. <https://github.com/marianapbento/libtexture.git>.
- [2] Levy Boccato and Romis Attux. Redes Neurais Convolucionais. Material da disciplina IA048 - Aprendizado de Máquina. DCA/FEEC/UNICAMP, 2022.
- [3] A. Géron. *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems*. O'Reilly Media, 2019.

- [4] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition, 2015.
- [5] Romy Hoque, Christina Ledbetter, Eduardo Gonzalez-Toledo, Vivek Misra, Uma Menon, Meghan Kenner, Alejandro A. Rabinstein, Roger E. Kelley, Robert Zivadinov, and Alireza Minagar. The role of quantitative neuroimaging indices in the differentiation of ischemia from demyelination: An analytical study with case presentation. In *The Neurobiology of Multiple Sclerosis*, volume 79 of *International Review of Neurobiology*, pages 491–519. Academic Press, 2007.
- [6] César Magro Checa, Danielle Cohen, Eduard L.E.M. Bollen, Mark A. van Buchem, Tom W.J. Huizinga, and Gerda M. Steup-Beekman. Demyelinating disease in sle: Is it multiple sclerosis or lupus? *Best Practice & Research Clinical Rheumatology*, 27(3):405–424, 2013. Systemic Lupus Erythematosus.
- [7] ScikitLearn. *sklearn.svm.LinearSVC*. <https://scikit-learn.org/stable/modules/generated/sklearn.svm.LinearSVC.html> [Accessed: 12.12.2022].
- [8] Jiancheng Yang, Rui Shi, Donglai Wei, Zequan Liu, Lin Zhao, Bilian Ke, Hanspeter Pfister, and Bingbing Ni. Medmnist v2: A large-scale lightweight benchmark for 2d and 3d biomedical image classification. *arXiv preprint arXiv:2110.14795*, 2021.